TECHNICAL RESEARCH REPORT

26 OCT 2026 · EDITION 1.0

PROJECT CODENAME: NOCAP

NOCAP.

UNSLOP FOR POLISH

Analiza UNSLOP, ograniczeń polszczyzny
i istniejących rozwiązań open source

Badanie architektury · analiza możliwości ponownego użycia · plan budowy i ewaluacji

Status: analiza techniczna i propozycja systemu, nie dokumentacja gotowego produktu.

UNSLOP SKILL 2.3.0 · SNAPSHOT REPORTED IN SOURCE RESEARCH: 17ed39c9 · DATA 26.10.2026

01 / EXECUTIVE SUMMARY

Decyzje przed implementacją

> **Teza:** NOCAP powinien być konserwatywnym edytorem polskich tekstów. Skaner zgłasza kandydatów; decyzję o zmianie podejmuje analiza kontekstu, a walidator ma prawo odrzucić każdą poprawkę.

01 **UNSLOP daje proces, nie gotową polską detekcję**
Agent skill łączy audit, frazy, strukturę dokumentu, contextual review, minimal rewrite i preservation gates. Bieżąca implementacja jest anglocentryczna. [01–03, DR]

02 **Bezpieczny no-op jest funkcją produktu**
Tekst bez potwierdzonych wad powinien wrócić identyczny. Liczby, negacja, warunki, modalność, cytaty, nazwy i głos autora mają pierwszeństwo przed „naturalnością".

03 **Benchmark UNSLOP nie uzasadnia automatycznego wdrożenia**
Wynik v9: większy recall i repair, lecz nieosiągnięte bramki precision, damage i whole-document improvement. Decyzja autorów: **NO-SHIP**. [04]

04 **Polskie OSS to materiał do adaptacji**
`pisz-po-ludzku`, `polish-humanizer`, `humanizer-polish` i `miodkuj` zawierają skanery, reguły, testowe pomysły i ochronę treści; brak porównywalnego, wspólnego benchmarku.

05 **MVP: hybryda deterministyczna + LLM**
Unicode, chronione zakresy, kontekstowo oceniane findings, lokalna poprawka, walidatory polszczyzny i regression corpus. Ciężki parser NLP dopiero po pomiarze wartości dodanej.

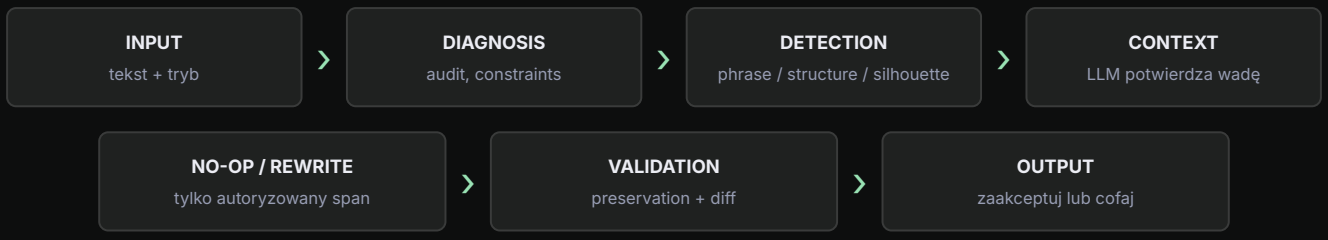
06 **Najpierw safety contract i pomiar**
Budowa systemu od podstaw jest uzasadniona wyłącznie tam, gdzie obecne elementy nie chronią znaczenia albo nie generalizują poza wąski korpus.

Klucz do oznaczeń: POTWIERDZONE = sprawdzone w wskazanym źródle; WNIOSKOWANE = interpretacja danych; HIPOTEZA = plan do testu; NIEZWERYFIKOWANE = brak audytu kodu lub wyników. „DR" oznacza przekazany tekst Deep Research.

02 / ORYGINALNY UNSLOP

Przepływ, komendy i odpowiedzialności

ARCHITEKTURA OPERACYJNA · na podstawie dokumentacji UNSLOP [01–03]



Cztery ścieżki pracy

TRYB	FUNKCJA
`rewrite`	Pełna diagnoza i lokalna przebudowa tekstu po akceptacji findings.
`cleanup`	Zgłasza propozycje do przeglądu bez bezwarunkowego rewrite.
`teach`	Wyprowadza profil głosu z zaakceptowanych próbek autora.
`mimic`	Przepisuje zgodnie z profilem przy zachowaniu safety gates.

Granice odpowiedzialności

- **Skaner:** wykrywa trafienie, strukturę i pozycję, lecz nie stwierdza samodzielnie błędu.
- **LLM:** odrzuca false positives i ustala minimalną korektę.
- **Validator:** porównuje zakres zmian i dane chronione; failure oznacza fallback.
- **Agent skill:** kieruje do właściwego polecenia, presetów i źródeł kontekstu.

HIT SKANERA → „Warto podkreślić” w cytacie artykułu → BRAK EDYCJI

Routing do `references/commands/*` oraz jeden `references/core-contract.md` umożliwiają progressive disclosure. Dane o aktualnym drzewie i wersji 2.3.0 pochodzą z DR, a publiczna obecność komend i kontraktu jest potwierdzona na GitHub. [01, 02, 05]

02 / ORYGINALNY UNSLOP

Skanery i ochrona znaczenia

PHRASE

Literalne frazy i regexy. W badanej wersji DR raportuje **16** wyzwalaczy runtime. Maskowanie cytatów i kodu ogranicza fałszywe trafienia.

STRUCTURE

DR raportuje **36** wzorców; powtórzone początki, triady, signpost density, długość i zmienność zdań.

SILHOUETTE

Układ argumentu i dokumentu: scaffold openers, preview fulfillment, role entropy, callback content. Niski dowód generalizacji poza własny zbiór.

Walidacja nie może być tylko instrukcją promptu

WARSTWA	ELEMENTY	CO WYMAGA ZMIANY W PL
Constraint extraction	Liczby, daty, kwoty, cytaty, referencje	Parser przecinków dziesiętnych, form dat i polskich cytatów.
Semantyka	Negacja, modalność, warunek, zakres	Nowe rodziny lematów, składnia i scope; angielskie regexy nie wystarczą.
Edits / diff	Zmienione spany, pokrycie, reszta tekstu	Unicode i mapowanie oryginalnych offsetów; neutralne koncepcyjnie.
Voice / register	Głos autora i ustalony ton	Polskie function words, formy Pan/Pani/Państwo, odmiana nazw.
Hard gates	Blokada naruszeń i fallback	Nie przyjmować wyniku przy niepewności co do faktu w domenie wysokiego ryzyka.

Kontrakt zachowania

Chroń liczby, przypisane opinie, cytaty, kod, modalność, terminologię i stopień pewności. Bez potwierdzonego problemu wykonaj **exact no-op**.

Czego testy techniczne nie dowodzą

36/36 struktur i 16/16 wyzwalaczy oznacza zgodność implementacji z fixture tests, a nie wysoką precyzję redakcyjną na obcym korpusie.

Wynik wewnętrznego silhouette testu (12/12 przykładów AI i 0/8 ludzkich) raportowany w DR jest obarczony bardzo małą próbką i ryzykiem dopasowania do własnej kolekcji. [DR, 01, 03]

03 / ENGLISH BEHAVIOR

Co UNSLOP wykrywa w angielskim

Lista poniżej opisuje **rodziny sygnałów redakcyjnych**, nie prawdopodobieństwo, że autorem jest model. Przykłady są ilustracjami opracowanymi do tej syntezy. [01–03, DR]

KATEGORIA	PRZYKŁAD EN	SYGNAŁ I WŁAŚCIWA KOREKTA
Formulaic opener	“In today’s fast-paced world…”	Wprowadzenie nic nie wnosi. Zacząć od tezy, jeśli sens zostaje.
Inflated significance	“a pivotal cornerstone…”	Sztucznie podniesiona ranga. Usunąć wartościowanie bez dowodu.
Empty emphasis	“It is important to note…”	Meta-komentarz zamiast faktu. Zostawić właściwą informację.
Artificial contrast	“It’s not X, it’s Y.”	Wzorzec retoryczny; sprawdzić, czy kontrast rzeczywisty.
Vague attribution	“Experts suggest…”	Brak wskazanego źródła. Bez dowodu nie tworzyć nowej atrybucji.
Chatbot artifacts	“Certainly! Here is…”	Metapreambuła w gotowej publikacji; usunąć tylko przy niewłaściwym medium.
Structural repetition	“First… Second… Finally…”	Mimowolne powtarzanie szablonu; nie ruszać proceduralnej listy.
Document silhouette	Powtarzalny układ akapitów i wniosków	Oceniać kompozycję całości, nie pojedynczą frazę.
Artificial rhythm	Jednakowe zdania / sztuczny staccato	Poprawiać realne miejsce tarcia, nie optymalizować CV zdań.

Reguła przenoszenia: tylko wzorzec, który ma negatywny wpływ w konkretnym rejestrze, zostaje kandydatem do poprawy. „Nie X, lecz Y”, trójka wyliczeniowa i krótkie zdanie nie są wadą z definicji.

03 / EVIDENCE & FAILURE

Benchmark UNSLOP v9: wynik NO-SHIP

> **POTWIERDZONE w publicznym raporcie UNSLOP:** trafniejsza detekcja nie wystarczyła, by produkt spełnił warunki bezpiecznej redakcji. Dane odnoszą się do konkretnego eksperymentu z modelem Luna; nie do polszczyzny. [04]

METRYKA	LUNA + UNSLOP	PLAIN LUNA	PRÓG V9
Detection precision	81,25%	83,33%	≥ 90%
Detection recall	83,87%	32,26%	≥ 90%
Repair success	87,10%	58,06%	≥ 90%
Preservation	100%	100%	100%
Damage rate	11,11%	0%	0%
Dirty docs safely improved	0/3	0/3	≥ 80%
Clean exact no-op	1/1	1/1	100%

Co zadziałało

Wzrost **recall o 51,61 p.p.** i **repair success o 29,04 p.p.** względem plain Luna w tym samym zestawie. Niezmienność liczb i czysty no-op przeszły test.

Co zablokowało wydanie

Precision poniżej progu, **11,11% collateral damage** i brak dokumentu poprawionego bezpiecznie end-to-end. Over-editing tekstu technicznego i cytowanych ocen.

Implikacja dla NOCAP

Projekt musi mieć odrębne metryki `finding precision`, `repair success`, `preservation`, `damage` i `document net improvement`. Błędny rewrite lub uszkodzenie chronionego spanu ma ważyć więcej niż niezauważona drobna klisza. Nie należy sumować tych wymiarów do jednego „AI-score".

> Nie interpretować `preservation 100%` jako całkowitego braku szkód: raport odrębnie wykazuje 11,11% damage rate. To różne operacjonalizacje metryk.

04 / POLISH CONSTRAINTS

Dlaczego polski wymaga innego silnika

TECHNICZNE

Tokenizacja ASCII, angielskie function words i kalendarz nie nadają się do polskiego. Potrzebne segmentacja Unicode, language routing `pl/en/mixed/unknown` i polskie parsery.

LINGWISTYCZNE

Przypadki, aspekt, ruchomy szyk, pro-drop, imiesłowy, nominalizacje i bezosobowość. Regex wykrywa poszlakę, ale często nie potrafi ocenić konstrukcji.

STYLISTYCZNE

„Oto…", nadmierna oficjalność, kalki, marketingowy naddatek, błędne Pan/Państwo, sztuczny format i mechaniczna puenta.

Problemy, których nie rozwiąże słownik synonimów

ZJAWISKO	DLACZEGO NIE MOŻE BYĆ HARD BLACKLIST	MECHANIZM DOCELOWY
„należy", „powinien"	Norma lub tekst naukowy wymaga tej modalności.	Reguły gatunku + preservation modalności.
Nominalizacje	„Zawarcie umowy" jest terminem prawa.	Gęstość + POS/lemma + kontekst.
Szyk zdań	Polski dopuszcza różne porządki tematyczno-rematyczne.	Kontekst i opcjonalnie dependency.
Imiesłowy	Naturalne, zależne od poprawnej relacji podmiotów.	Segmentacja + analizator morfosyntaktyczny.
Formy Pan/Pani/Państwo	Rejestr wynika z odbiorcy i medium.	Classifier + spójność w dokumencie.
Cytaty i cudzysłowy	„…", „…" i znaki kodu mają inne funkcje.	Chronione spany + polityka medium.

> **Klasy zmian:** NIEOBSŁUGIWANE (polska negacja w validatorze EN); NIEPRZETESTOWANE (silhouette na polskim); ADAPTACJA (struktura); REUSE (no-op i benchmark). [DR, 01–03]

PolEval 2025/Śmigiel: najlepsze systemy przekroczyły 90% accuracy w głównym zadaniu detekcji autorstwa, lecz traciły jakość na nowych domenach i generatorach. CEAID wskazuje ryzyko przenoszenia detektorów między językami Europy Środkowej. To argument za wielodomenową **ewaluacją edytora**, nie za klasyfikatorem AI w NOCAP. [20, 21]

05 / COMPARATIVE MATRIX

EN → PL: mapa decyzji

To macierz komponentów, nie tabela jakości projektów. Klasyfikacja dotyczy pracy potrzebnej do powstania polskiego systemu. [DR, 01–03]

MECHANIZM	EN DZIŚ	PL DZIŚ / BARIERA	DECYZJA
Editing contract	Działa w skillu	Sens zasad przenośny	**REUSE**
No-op	Wymagany w benchmarku	Językowo neutralny	**REUSE**
Phrase scanner	Angielskie triggery	Inny słownik i fleksja	**REBUILD**
Lang detection	EN function words	ASCII i krótkie inputy	**REBUILD**
Quote/code mask	Istnieje	Polskie znaki cytowania	**ADAPT**
Structural scan	36 wzorców w DR	Próg zależy od gatunku	**ADAPT**
Silhouette	Implementacja EN	Brak walidacji PL	**VERIFY**
Readability	Formuły EN	Nieprzenośne bez danych	**REBUILD**
Numbers/dates	Walidatory EN	„3,5”, „mln”, formy dat	**ADAPT**
Negation	Angielskie cues	Odmiana i scope	**REBUILD**
Modality	Angielskie cues	móc / musieć / powinien	**REBUILD**
Conditions	Angielskie cues	jeżeli / chyba że / wyjątki	**REBUILD**
Register	Mainly prompt-level	Ty / Państwo / role	**NEW**
Voice profile	EN function words	Nowa kalibracja PL	**ADAPT**
Benchmark protocol	Holdout + blind judge	Zbiór i annotatorzy PL	**REUSE**
Authorship score	Nie jest celem edycji	Nie używać jako KPI	**DROP**

> **VERIFY** nie jest oceną negatywną. Oznacza, że bez polskiego testu nie wolno wdrażać progu lub stawiać twierdzenia o jakości.

06 / PRZED → PO → DLACZEGO

Polski slop: miejscowe poprawki

Przykłady syntetyczne opracowane na podstawie taksonomii DR i polskich repozytoriów. Są propozycjami testowymi, a nie wynikami działania istniejącego NOCAP. [DR, 06–10]

01 Preambuła

PRZED
Oto propozycja artykułu: API udostępnia trzy nowe mechanizmy.

PO
API udostępnia trzy nowe mechanizmy.

DLACZEGO · Usunięto metawprowadzenie; wyłącznie gdy to finalny artykuł, nie odpowiedź w czacie.

02 Puste wartościowanie

PRZED
Warto podkreślić, że liczba zgłoszeń spadła o 12%.

PO
Liczba zgłoszeń spadła o 12%.

DLACZEGO · Usunięto frazę bez wartości informacyjnej; 12% pozostaje identyczne.

03 Nominalizacja

PRZED
W celu dokonania analizy logów uruchomiono skrypt.

PO
Aby przeanalizować logi, uruchomiono skrypt.

DLACZEGO · Krótszy predykat. Rejestr prawny mógłby wymagać innej decyzji.

04 Kalka biurowa

PRZED
Musimy zaadresować ten problem w kolejnej iteracji.

PO
Musimy zająć się tym problemem w kolejnej iteracji.

DLACZEGO · „Zająć się" nie obiecuje rozwiązania; poprawka nie wzmacnia zakresu zobowiązania.

05 Wymuszony kontrast

PRZED
Zmiana dotyczy nie tylko wydajności, ale również bezpieczeństwa.

PO
Zmiana dotyczy wydajności i bezpieczeństwa.

DLACZEGO · Tylko gdy poprzedni kontrast niczego nie rozstrzyga.

06 Artefakt Markdown

PRZED
Ważne: Termin wynosi 14 dni.

PO
Ważne: Termin wynosi 14 dni.

DLACZEGO · Tylko w medium plain text. W Markdown poprawka byłaby błędem.

07 Rejestr B2B

PRZED
Szanowni Państwo, możesz sprawdzić swoje konto.

PO
Szanowni Państwo, mogą Państwo sprawdzić swoje konto.

DLACZEGO · Ujednolicono zwrot do odbiorcy; wymagane potwierdzenie formalnego rejestru.

08 Bezpodstawny patos

PRZED
Ta przełomowa, niezwykle ważna zmiana ułatwia eksport CSV.

PO
Ta zmiana ułatwia eksport CSV.

DLACZEGO · Przymiotniki nie miały uzasadnienia. Nie dodano nowych obietnic.

06 / NO CHANGE

Gdy najlepsza poprawka nie istnieje

Konstrukcja podejrzana statystycznie bywa poprawna. Poniższe przykłady są syntetycznymi testami ochronnymi. Oczekiwane zachowanie: **NO CHANGE**, najlepiej byte-exact.

PRZYKŁAD	DLACZEGO ZOSTAWIĆ
„Wykonawca zobowiązuje się…" (powtórzone 7 razy)	Termin zdefiniowany w umowie; nie synonimizować.
„Wyniki mogą sugerować związek…"	Słowo „mogą" ogranicza pewność naukową.
„Należy złożyć wniosek w ciągu 14 dni."	Normatywny rejestr i obowiązek z terminem.
„Nie tylko A, lecz także B" w sprostowaniu	Prawdziwy kontrast semantyczny.
„Dedykowany serwer jest wyłączony."	Termin techniczny, nie marketingowa kalka.
„Konfiguracja**" w pliku Markdown**	Prawidłowy format źródłowy.
„Mam nadzieję, że u Ciebie wszystko dobrze."	Naturalny ton wiadomości prywatnej.
Wyliczenie trzech kroków API	Trójka elementów jest właściwa procedurze.
„Co najmniej 3,5 mln zł"	Kwantyfikator, przecinek i jednostka są chronione.
Cytat: „W dzisiejszych czasach…"	Cytat jest źródłem, nie autorską prozą.
„Wniosek Kowalskiego…"	Odmiana nazwiska jest poprawna.
„Chyba że administrator wyrazi zgodę"	Wyjątek prawny zmienia warunek; chronić.

Jak mierzyć nadmierną redakcję

Clean FPR: odsetek dobrych przypadków zgłoszonych jako wadliwe. **Exact no-op:** odsetek czystych dokumentów zwróconych identycznie.

Kiedy wolno odstąpić od no-op

Tylko po wskazaniu konkretnej wady w danym gatunku, potwierdzeniu kontekstu i zaliczeniu wszystkich bramek ochronnych.

Ujęcie to wynika z kontraktu UNSLOP i katalogu polskich false positives w DR. [02, DR]

07 / OPEN-SOURCE LANDSCAPE

Pięć głównych źródeł dla NOCAP

Ocena poniżej dotyczy **przydatności projektowej**, nie zmierzonej przewagi w jakości pisania. Licencje według dokumentacji/DR; przed kopiowaniem kodu wymagany audyt konkretnych plików.

pisz-po-ludzku github.com/wysocki-lu/pisz-po-ludzku

Rodzaj: polski skill i skaner JS. **Wartość:** leksykon, rejestr Pan/Pani/Państwo, katalog wyjątków, hard/soft rules, false-positive cases. **Ryzyko:** preskryptywne zakazy znaków, brak reprezentatywnego benchmarku. **Strategia:** ADAPT reguły, nie importować na ślepo. [06, DR]

polish-humanizer github.com/mkh63d/polish-humanizer

Rodzaj: skill + skaner `scripts/skan.py`. **Wartość:** Unicode, segmentacja, nominalizacje, rytm, formy bezosobowe, JSON, porównanie wersji. **Ryzyko:** progi rytmu i heurystyki suffixów nieskalibrowane. **Strategia:** ADAPT engine/metryki. [08, DR]

humanizer-polish github.com/empios/humanizer-polish

Rodzaj: skill + skrypty analizy i kontroli. **Wartość:** porównanie liczb, podstaw prawnych, modalności, przeczeń i ról. **Ryzyko:** zakres skuteczności guardów wymaga fixture audit. **Strategia:** ADAPT preservation. [09, DR]

miodkuj github.com/bartekpucek/miodkuj

Rodzaj: polski system skill / dystrybucja wieloplatformowa. **Wartość:** minimal edit, audyt bez redakcji, rejestry, źródła, testy. **Ryzyko:** niepełny code-level audit w DR. **Strategia:** benchmark baseline i architektura skilla. [10, DR]

sonda-bielika github.com/wysocki-lu/sonda-bielika

Rodzaj: korpus i eksperyment badawczy. **Wartość:** 60 tekstów Bielik 11B, układ generowania próbek i kategorie polskich wzorców. **Ryzyko:** jeden model/marketing i niespójny count markdown bold (489 vs 165). **Strategia:** ADAPT metodę, nie dane jako benchmark całej polszczyzny. [07, DR]

07 / OPEN-SOURCE LANDSCAPE

Pozostałe projekty i granice dowodu

PROJEKT I REPOZYTORIUM	PRZYDATNY MECHANIZM	DECYZJA I OGRANICZENIE
ai-slop-detect	CLI EN/PL; JSON, katalog deklarowanych 70+ patternów	ADAPT vocabulary + format; score nie jest prawdopodobieństwem AI.
pielas-activy/humanizer-pl	Dwujęzyczny routing, Bielik/Ollama optional	RESEARCH; lineage fork i prawa do kodu (NOASSERTION w DR).
codex-humanizer-pl	Integracja Codex, testy regresyjne, layered QA	ADAPT interface; prawa fork wymagają odrębnego sprawdzenia.
PawelASzczesny/humanizer-pl	41 wzorców deklarowanych, wyjątek prawny	RESEARCH; brak pełnego audytu kodu/ wyników w DR.
odwrotnie/humanizer-pl	Źródłowy katalog polskich markerów	RESEARCH; dokumentacja tak, implementacja niezweryfikowana.
piszpoludzku	Poziomy redakcji i skill użytkowy	Niski priorytet do czasu dowodu odrębnej wartości.

Jak nie pomylić skryptu z dobrym redaktorem

DEKLARACJA

README informuje o intencji autora i interfejsie. To hipoteza funkcjonalna, nie wynik pomiaru.

KOD / TEST

Istnienie pliku i fixture potwierdza mechanikę w testowanych przypadkach, nie odporność poza nimi.

BENCHMARK

Dopiero zamrożony korpus, blind adjudication i porównywalne ramiona mówią o jakości netto.

Status audytu: badanie źródłowe było nierównomierne. Najdokładniej opisano UNSLOP, `pisz-po-ludzku`, `sonda-bielika` i `polish-humanizer`. Pozostałe repozytoria wymagają replikacji testów, przeglądu commitów, zależności i licencji. [DR, 11–16]

08 / JUMP START · PART I

Co zaadaptować w pierwszym etapie

Macierz implementacyjna. **P0** oznacza element blokujący bezpieczne MVP, nie zgodę na skopiowanie pliku z obcego repozytorium.

KOMPONENT	KANDYDAT	STRATEGIA	WARUNEK / PRIORYTET
Safety contract	UNSLOP	ADAPT	Polskie invarianty; licencja przed kopiowaniem · P0
Audit-before-edit	UNSLOP	REUSE idea	Finding ≠ zmiana · P0
Exact no-op	UNSLOP evals	REUSE idea	Byte-exact fixtures · P0
Katalog polskich fraz	pisz-po-ludzku + sonda	ADAPT	Wyjątki, dowód, deduplikacja · P0
Skaner fraz	polish-humanizer + UNSLOP	REIMPLEMENT	Unicode i one source of truth · P0
Maskowanie kodu/cytatów	UNSLOP + humanizer-polish	ADAPT	Polskie cudzysłowy i fenced code · P0
Język mixed	nowy moduł	REIMPLEMENT	pl/en/mixed/unknown; nie zgadywać · P0
Segmentacja zdań	skan.py	ADAPT	Skróty, liczby, jednolity offset · P0
Rejestr i Ty/Państwo	pisz-po-ludzku	ADAPT	Branże, cytaty, formalność · P0
Diff / edit surface	UNSLOP	REUSE idea	Nie dotykać odrzuconych spans · P0
Parsers liczb/dat	UNSLOP + empios	REIMPLEMENT	„3,5 mln”, zakresy, 14 dni · P0
LLM adjudicator	UNSLOP concept	REIMPLEMENT	Decyzja confirmed/rejected z rationale · P0

> **Zalecany minimalny audyt repozytoriów:** UNSLOP → pisz-po-ludzku → polish-humanizer → humanizer-polish → miodkuj. Z `sonda-bielika` wziąć metodologię tworzenia wąskiego korpusu, nie globalne progi.

08 / JUMP START · PART II

Czego nie wolno importować bez walidacji

KOMPONENT	ŹRÓDŁO / STRATEGIA	WERYFIKACJA PRZED PRZYJĘCIEM
Nominalizacje / bezosobowość	polish-humanizer / ADAPT	Morfologia i false positives w naukowym/ prawnym.
Rytm / burstiness	polish-humanizer + UNSLOP / ADAPT	Progi per genre; baseline ludzkich tekstów.
Structure/silhouette	UNSLOP / RESEARCH	Ablacja na polskim holdoucie, bez AI-authorship labels.
Negacja / modalność / warunki	empios / REIMPLEMENT	Przykłady T22–T25 + zakres wypowiedzi.
Referencje / role stron	empios / ADAPT	Polskie podstawy prawne i odmiana nazw.
Minimal rewrite	UNSLOP / ADAPT	Uprawnione spany i walidacja semantyki.
Benchmark runner	UNSLOP / ADAPT design	Identyczny model, brak ukrywania failures.
Regression fixtures	wszystkie repo / NEW	Positive, negative, no-op, protected-span.
Voice teach/mimic	UNSLOP / RESEARCH	Stylometria PL; dopiero V2.
CLI/CI JSON	ai-slop-detect / ADAPT	Stabilne schema, nie „AI probability”.
Dystrybucja skill	miodkuj + writing-for-agents / ADAPT	Routing, referencje, testowalne done criteria.

Ryzyka integracji

Prawne i technologiczne

Różne deklaracje licencji; zależności skryptów JS/ Python; nadmiar zewnętrznych parserów; zmiana zachowania na aktualizacji modelu.

Językowe i metodologiczne

Powielone wzorce, sprzeczne reguły typografii, różne formaty findings, dług techniczny kilkunastu glossary packs oraz stronnicze testy.

Decyzja: jeden kanoniczny `PatternSpec` z `id, evidence, severity, contexts, exceptions, fixtures`. Inne repozytoria mogą zasilać review queue; nie stają się równoległymi silnikami prawdy.

09 / GAPS & EXPERIMENTS

Co rzeczywiście pozostaje do zbudowania

LUKA	OBECNY STAN	PROPOZYCJA / TEST WARTOŚCI
Kontekst vs blacklist	Istnieją lists i heurystyki.	Adjudicator dla raw hitów; mierzyć wzrost precision i clean FPR.
Analiza fleksji	Suffix regex + ogólne NLP tools.	Optional POS/lemma w V1; ablacja FPR/ czasu.
Meaning preservation PL	Częściowe guardy, brak wspólnego kontraktu.	Negacja, modalność, przyczynowość, scope; testy par semantycznych.
Kontrola dokumentu	Diff/structure w kilku repo.	Span-level i document-level gates; mierzyć collateral damage.
Rejestr i głos	Zalecenia skilli, mało zamrożonych testów.	State machine rejestru, voice score V2; blind human review.
Benchmark wielogatunkowy	Bielik: wąski korpus; UNSLOP: EN.	Polski clean + dirty + mixed holdout; raport per genre.
Update nowych wzorców	Ręczne katalogi i README.	Evidence queue; każdy nowy pattern musi mieć negative fixture.
Architektura agentowa	Rozdzielone skille i skrypty.	Mały routing skill + moduły wykonywalne; completion gates.

Nie zakładać, że większa technologia znaczy większą trafność

Ablacja A

Regex/stem + contextual LLM vs lemma/POS + LLM. Różnicę mierzyć na tych samych polskich tekstach i identycznym modelu.

Ablacja B

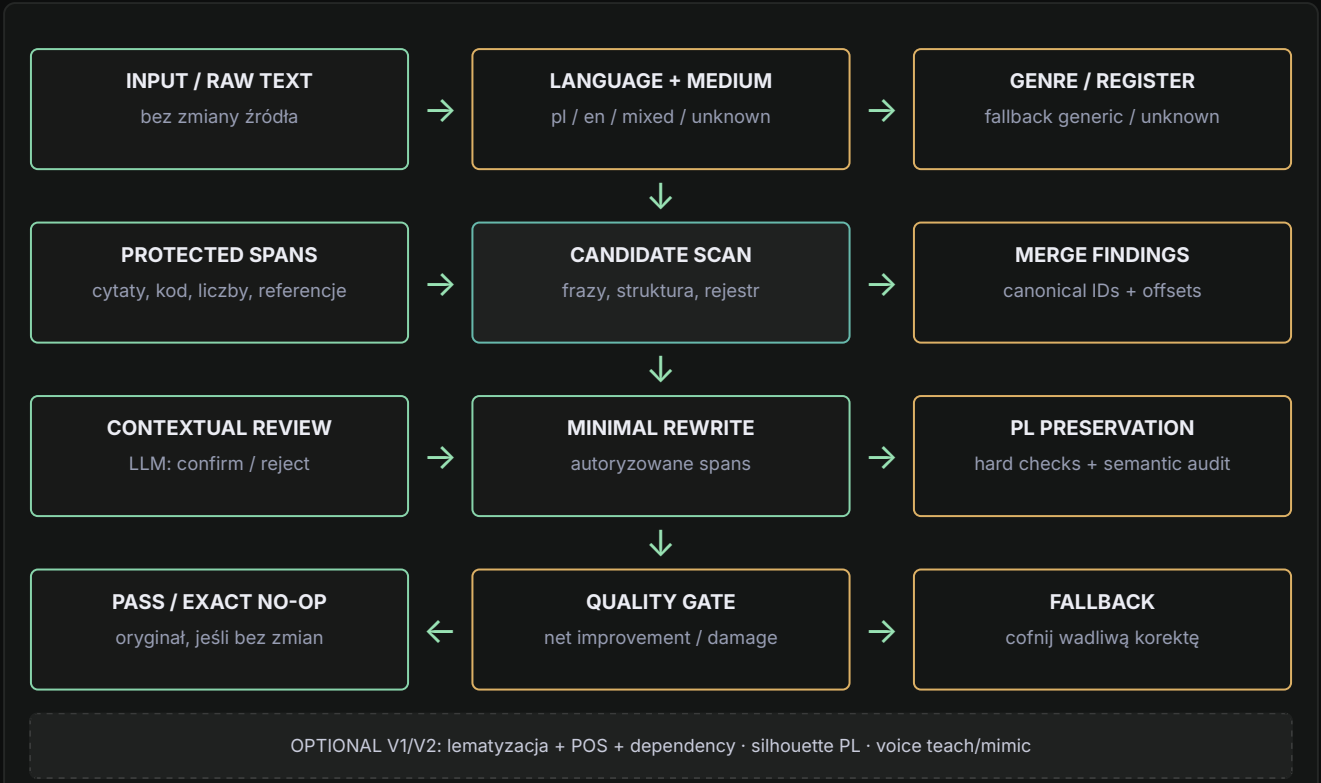
Frazy + register vs dodatkowy structure/silhouette. Uruchomić tylko, jeśli daje net improvement bez szkody clean docs.

Stanza i spaCy zapewniają polskie komponenty NLP, ale ich praktyczna korzyść dla edytora NOCAP pozostaje hipotezą. Nie traktować gotowego modelu NLP jako dowodu jakości redakcji. [DR, 17–18]

10 / ARCHITECTURE PROPOSAL

NOCAP: pipeline z twardymi bramkami

zasada UNSLOP · adaptacja PL OSS · nowa warstwa · opcjonalne



Granice modułów

MODUŁ	ZWRACANY KONTRAKT / INVARIANT
Protection	Spany nieedytowalne i znaczniki semantyczne zawsze indeksowane względem oryginału.
Scanner	Raw candidate z dokładnym start/end, źródłem reguły i kontekstem; nigdy rewrite.
Adjudicator	`confirmed/rejected/uncertain` + uzasadnienie; `uncertain` nie zmienia tekstu.
Rewrite	Ograniczona podmiana i diff; brak nowych faktów, opinii i zmiany siły twierdzeń.
Validator	`pass/fail` + reason codes; hard failure cofa lokalną zmianę lub dokument.

Wszystkie elementy tego diagramu to **propozycja**, nie wdrożona architektura NOCAP.

10 / CONTRACTS & AGENT SKILL

Jedna prawda, minimalny kontekst

Finding jako dane, nie opinia

```
{
  "id": "PL-NOMINALIZATION:17",
  "start": 418, "end": 451,
  "status": "confirmed",
  "genre": "business",
  "risk": "soft",
  "replacement": "aby przeanalizować",
  "validation": "pending"
}
```

Przykład syntetyczny formatu. Offsety odnoszą się do niezmiennego oryginału; confidence dotyczy dopasowania reguły, nie autorstwa AI.

Minimalne drzewo skilla

```
SKILL.md
  references/core-contract.md
  references/commands/{audit,rewrite}.md
  references/patterns/*.md
  references/registers/*.md
  references/preservation/*.md
  evals/{runner,metrics,fixtures}
```

`SKILL.md` ma wskazywać, kiedy doczytać reguły. Context pointers, single source of truth i completion criteria pochodzą z `writing-for-agents`. [05]

Warunki ukończenia operacji

ETAP	PRZEJŚCIE DALEJ TYLKO WTEDY, GDY…
Candidate scan	Każdy hit ma dokładny span; spany chronione są oznaczone.
Context review	Każdy kandydat ma decyzję; przy niepewności pozostaje bez zmiany.
Rewrite	Zmiana nie wykracza poza uprawnione spany po mapowaniu offsetów.
Preservation	Liczby, negacja, modalność, warunki, strony i cytaty nie zostały uszkodzone.
Output	Hard gates przechodzą; w przeciwnym razie fallback + reason code.

Kontrakt dziesięciu reguł: konkretna wada, kandydat ≠ decyzja, najmniejszy span, wyjątek językowy, ten sam stopień pewności, brak nowej przyczynowości, ten sam agent i role, ta sama modalność i warunek, brak zbędnej synonimizacji, dokładny no-op bez findings.

11 / DELIVERY ROADMAP

MVP → V1 → V2

01 MVP FUNDAMENT

Budować: model dokumentu i offsetów, `PatternSpec`, detekcję PL/mixed, chronione spany, phrase/register scanners, adjudicator, minimal rewrite, numeryczne i semantyczne PL gates.

Źródła: UNSLOP (proces), pisz-po-ludzku (taksonomia), polish-humanizer (scanner), humanizer-polish (preservation).

DoD: każdy hit ma span; każdy pattern positive+negative fixture; exact no-op; hard fixtures przechodzą; benchmark i rollback działają.

Ryzyko: fałszywe trafienia i nadmierna ingerencja.

02 V1 POLISH INTELLIGENCE

Budować: lemma/POS adapter po ablacji, dodatkowe gatunki, analiza składni, mocniejsza spójność rejestru, document structure, wielomodelowy holdout i blind annotation.

Źródła: Stanza/spaCy (opcjonalne NLP), UNSLOP structure, polskie pattern packs.

DoD: potwierdzony lift netto względem MVP i baseline, rozbicie per genre i family, bez wzrostu collateral damage.

Ryzyko: overfitting oraz koszt i latency parsera.

03 V2 ADVANCED WRITING

Budować: voice teach/mimic PL, profile domenowe, telemetryka driftu, eksperymenty z silhouette i oceną dyskursu.

Źródła: UNSLOP voice i metodologia oceny; Miodkuj jako baseline dystrybucji.

DoD: mierzalna poprawa voice preservation, audyty domenowe, niezależny test bezpieczeństwa przy zachowaniu prywatności.

Ryzyko: koszt utrzymania, niejawne zmiany stylu i prywatność danych.

> Kolejność jest zależnościowa, nie kalendarzowa. Nie ma podstaw do wiarygodnego harmonogramu czasowego bez zakresu zespołu i próby implementacyjnej.

12 / VALIDATION DESIGN

Jak wykazać przewagę, zamiast ją ogłaszać

NOCAP nie ma dziś porównywalnego wyniku eksperymentalnego. Poniżej projekt badania i warunki wydania, nie osiągnięte metryki.

Ramiona testu

- Niezmieniony tekst źródłowy jako kontrola.
- Ten sam bazowy LLM bez skilla.
- Bazowy LLM + UNSLOP tam, gdzie technicznie dopuszczony.
- Wybrane polskie skille na porównywalnych danych.
- NOCAP przy tej samej wersji modelu i parametrach.

Korpus i adjudication

Propozycja: minimum 240 dokumentów, 6 gatunków × 40. Równoważyć dobre i wadliwe teksty ludzkie, LLM i ręcznie edytowane. Tune, holdout i niedostępny dla deweloperów holdback.

Dwóch niezależnych polskojęzycznych annotatorów + adjudication. Dla prawa/medycyny domenowy reviewer.

Wyniki, które należy raportować oddzielnie

DETECTION	SAFETY	JAKOŚĆ NETTO
Precision / recall findings	Protected span damage	Blind whole-document preference
Clean false-positive rate	Negation / modality / scope preservation	Repair success per family
Calibration per genre	Exact no-op on clean docs	Naturalność i rejestr
Overlaps / abstention	Collateral edit surface	Voice similarity + disagreement

Proponowane release gates

100% hard constraints na zamrożonych publicznych fixture; **0** chronionych spanów uszkodzonych w holdoucie; **100%** exact no-op dla „hard clean”. Pozostałe progi ustalić na tune przed otwarciem holdoutu.

No-ship jest prawidłowym wynikiem

Wyższy recall przy gorszej preservation oznacza regresję. Braki, timeouty i awarie są częścią mianownika. Nie optymalizować rewrite pod odchylenie długości zdań ani AI detector score.

Benchmark historyczny UNSLOP i metodologia holdout/blind judge: [04]. Projekt korpusu i progów NOCAP: HIPOTEZA badawcza na podstawie DR.

13 / RECOMMENDATIONS

KEEP / ADAPT / BUILD

KEEP

- Audit przed redakcją.
- Raw hit ≠ potwierdzony defekt.
- Minimalny span i exact no-op.
- Oddzielne preservation gates i fallback.
- Holdout, blind judge, raportowanie failures.
- Progressive disclosure skilla.

ADAPT

- Polskie katalogi wzorców i wyjątków.
- Scanner engine i segmentację.
- Metryki rytmu per gatunek.
- Maskowanie quote/code w Unicode.
- Diff i workflow porównania wersji.
- Dystrybucję agent skill / CLI.

BUILD

- PL language + register routing.
- Kanoniczne PatternSpec i findings.
- Polskie negative / modal / scope gates.
- Kontekstowy adjudicator.
- Benchmark clean/dirty/mixed.
- Ablacje i metryki szkód.

Najlepszy pierwszy sprint techniczny

NC-001/002

Model dokumentu, canonical spans i format findings.

NC-005/006/007

Protected spans, liczby, negacja, modalność, warunki.

NC-008/015/016

Scanner candidates, ≥35 syntetycznych fixture i runner baseline.

> **Decyzja inwestycyjna:** rozpocząć od ochrony znaczenia oraz testów, nie od dodawania setek fraz. NOCAP ma sens tylko, jeżeli na nieznanych polskich tekstach poprawia realne wady przy mniejszej liczbie szkód niż rozwiązania porównawcze.

Obecnie NOCAP jest **kryptonimem planu**. Nie istnieją tutaj wdrożony produkt, własne benchmarki ani liczby potwierdzające przewagę systemu.

14 / SOURCES & LIMITATIONS

Źródła, zakres weryfikacji i zastrzeżenia

Materiały główne

DR	„NOCAP (UNSLOP-PL): baza badawczo-techniczna...”; przekazany plik tekstowy, 26.10.2026. W raporcie za źródło wtórne przyjęto całą jego treść. Jego wewnętrznych oznaczeń cytowań nie da się niezależnie odtworzyć z samego pliku.
01	theclaymethod/unslop
02	UNSLOP core-contract.md
03	UNSLOP SKILL.md, 2.3.0
04	UNSLOP CORE-RESULTS.md
05	Writing for Agents / SKILL.md

Repozytoria polskie

06	wysocki-lu/pisz-po-ludzku
07	wysocki-lu/sonda-bielika
08	mkh63d/polish-humanizer
09	empios/humanizer-polish
10	bartekpucek/miodkuj

Pozostałe repozytoria

11	antydizajn/ai-slop-detect
12	pielas-activy/humanizer-pl
13	mateuszkozlowski/codex-humanizer-pl
14	PawelASzczesny/humanizer-pl
15	odwrotnie/humanizer-pl
16	delta240mvt/piszpoludzku

Narzędzia językowe / dalsze badania

17	Stanza: lematyzacja, POS, dependency parsing
18	spaCy: modele języka polskiego
19	UD Polish PDB
20	PolEval 2025 / Śmigiel: MGT detection
21	CEAID: Central European MGT benchmark

Ograniczenia materiału

Weryfikacja publicznych stron GitHub przeprowadzona 26.10.2026; nie wykonano pełnego lokalnego code-review i uruchomienia benchmarków każdego repozytorium. Dane historyczne, progi i commity podane przez DR nie zawsze były niezależnie potwierdzone. Niejednoznaczna licencja repo-level UNSLOP wymaga sprawdzenia przed reuse kodu.

Metodologia źródeł: potwierdzono publiczne repozytoria, bazowe pliki UNSLOP, skrypty `skan.py` i `porownaj_wersje.py` oraz metodę Writing for Agents. Benchmark v9 został sprawdzony w publikacji UNSLOP. Przykłady NOCAP, roadmapa, wartości progów proponowanych i architektura mają status projektu, a nie wyniku implementacji.